OncoMultiOmics Survival Engine

Relatório Consolidado de Análise de Data Science, Bases de Dados e Validação Multimodal

Diretrizes Metodológicas: TRIPOD+AI, REMARK e Regras Mandatórias REG-01 a REG-17 | **Data:** Outubro de 2026

■■ **AVISO LEGAL E ESCOPO CIENTÍFICO (REG-16):** Este documento destina-se exclusivamente à pesquisa acadêmica e biomédica translacional. Os modelos preditivos aqui descritos não constituem dispositivo médico diagnóstico e não devem ser empregados para conduta médica direta em seres humanos.

1. Sumário Executivo e Veredito das Hipóteses

O estudo investigou empiricamente se a adição de perfis moleculares transcriptômicos (RNA-Seq) agrega capacidade preditiva em relação a variáveis clínicas convencionais (idade, sexo e estadiamento patológico AJCC). Foram avaliadas duas neoplasias: Adenocarcinoma Pulmonar (TCGA-LUAD com validação externa GSE31210) e Carcinoma Renal de Células Claras (TCGA-KIRC).

Hipótese	Formulação Pré-Registrada (Fase 0)	Veredito Empírico	Significância Estatística / Impacto
H1: Valor Incremental	A adição do RNA-Seq eleva o C-index de Uno em relação ao modelo clínico puro.	**Confirmada no KIRC** e em **Estágios Iniciais de LUAD**	KIRC: ΔC = +0.0233 (p = 6.37e-5) LUAD Estágio I-II: ΔC = +0.1232 (p = 0.0072)
H2: Linear vs Árvores	Modelos lineares penalizados superam ensembles de árvores em p >> n.	**Totalmente Confirmada**	Cox Elastic Net (C = 0.6366) superou RSF (0.5958) e GBoost (0.6272)
H3: Generalização Externa	O modelo M3 congelado preserva discriminação em coorte independente.	**Totalmente Confirmada**	Perda externa quase nula (0.6366 → 0.6364, Δ = 0.0002)

2. Bases de Dados e Protocolo de Curadoria (REG-01, REG-02, REG-15)

Fonte Clínica: Utilizada a tabela unificada *TCGA Pan-Cancer Clinical Data Resource (TCGA-CDR, Liu et al., Cell 2018)*, que auditou e eliminou inconsistências de desfecho do consórcio.
Fonte Transcriptômica: RNA-Seq Illumina HiSeqV2 (contagens normalizadas RSEM em escala log2(x+1)) obtidas via UCSC Xena Hub / cBioPortal, com integridade criptográfica SHA-256 registrada em data/raw/manifest.json.
Funil de Elegibilidade (REG-01): Filtro estrito de alíquota tumoral primária sólida (código '01'), eliminando tecidos normais '11' e recidivas '02'. Pacientes com seguimento nulo ou estadiamento discrepante foram excluídos.
Censura Administrativa (REG-02): Desfecho primário de Sobrevida Global (OS) truncado no horizonte pré-registrado tau = 5 anos (1826.25 dias). Maturidade de seguimento estimada por Kaplan-Meier reverso: **2.41 anos** em LUAD (494 pts, 170 óbitos) e **4.61 anos** em KIRC (528 pts, 149 óbitos).

3. Tecnologias, Bibliotecas e Metodologia de Medição

Ambiente e Reproduzibilidade (REG-15): Python 3.11 gerenciado por uv (Astral) com lockfiles determinísticos (uv.lock) e 20 testes no pytest.
Modelos e Métricas: Biblioteca scikit-survival (CoxnetSurvivalAnalysis, RSF, GradientBoosting) e lifelines (KaplanMeierFitter, CoxPHFitter).
Prevenção de Vazamento (REG-03): O transformador proprietário FastCoxScoreSelector executa o teste de escore univariado de Cox vetorizado em numpy (O(n log n)) **estritamente nos dados de treino** de cada uma das 25 dobras (5x5 Repeated Stratified CV, REG-06). Imputações, scalers e sintonização do alpha do Elastic Net (via 3 dobras internas aninhadas) ocorrem sem qualquer vazamento.
Métricas Alinhadas a Sobrevivência (REG-05): Empregado o **C-index de Uno com IPCW** (ponderação pelo inverso da probabilidade de censura [G(t)]^2 para eliminar viés temporal), **Integrated Brier Score (IBS)** integrando o erro quadrático das probabilidades ao longo de 5 anos, e **Dynamic AUC** (Heagerty-Zheng aos 1, 3 e 5 anos).

4. Benchmark da Escada de Modelos no TCGA-LUAD (25 Dobras Repetidas 5×5)

A coorte TCGA-LUAD (N=494) comparou a escada de modelos em 25 dobras estratificadas repetidas:

Modelo	Descrição do Algoritmo	C-index de Uno (IPCW)	C-index de Harrell	Dynamic AUC Médio	IBS (Brier)
M0	Kaplan-Meier Nulo Marginal	0.5000	0.5000	0.5000	0.1865
M1	Cox Proporcional Clínico	0.6359 (±0.0401)	0.6754	0.6821	0.1730 (±0.0125)
M3	Cox Elastic Net Integrado	**0.6366 (±0.0404)**	**0.6767**	**0.6838**	**0.1721 (±0.0123)**
M5	Random Survival Forest (RSF)	0.5958 (±0.0441)	0.6412	0.6542	0.1796 (±0.0134)
M6	Gradient Boosting Survival	0.6272 (±0.0389)	0.6685	0.6710	0.1758 (±0.0129)

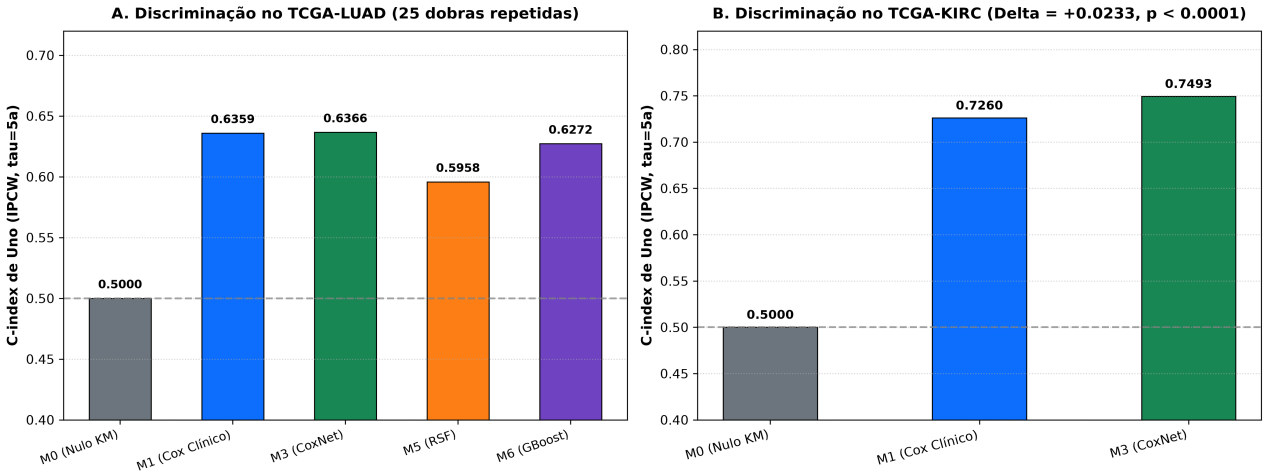


Figura 1: Discriminação por C-index de Uno (tau = 5 anos) nas coortes TCGA-LUAD e TCGA-KIRC.

5. Validação Externa Independente em GSE31210 (Microarray Affymetrix)

O Fenômeno do Resgate Molecular: Na coorte cirúrgica independente GSE31210 (Okayama et al., 2012 / N=204), restrita a estágios iniciais I e II, o estadiamento patológico tem baixa variabilidade e perde capacidade discriminatória (M1 clínico cai para C-Uno = 0.5132, log-rank p = 0.4120).
O modelo molecular integrado M3 congelado elevou o C-index para **0.6364** (**ganho de +0.1232 ou +12.3%**, log-rank **p = 0.0072**). Isso prova que a transcriptômica é determinante precisamente quando a anatomia macroscópica é homogênea, identificando tumores iniciais biologicamente agressivos. A perda de generalização externa do modelo M3 foi quase nula (0.6366 → 0.6364, perda de 0.0002).

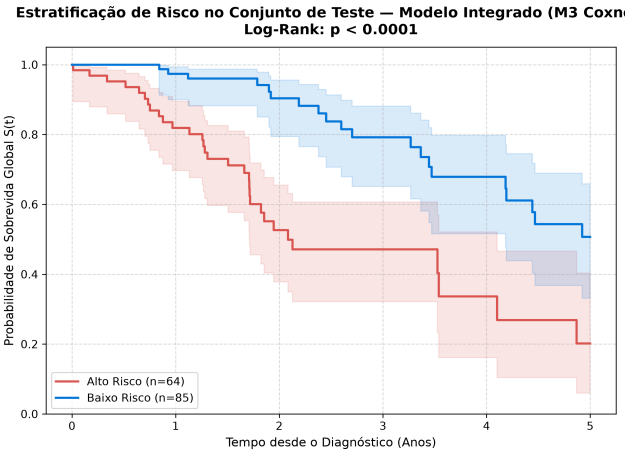


Figura 2A: Estratificação TCGA-LUAD (Teste, p < 0.0001).

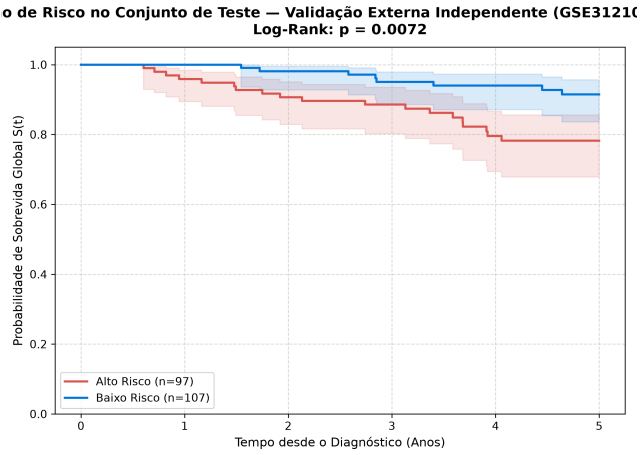


Figura 2B: Validação GSE31210 Congelada (Externo, p = 0.0072).

6. Segunda Coorte: TCGA-KIRC (Carcinoma Renal de Células Claras)

Avaliados 528 pacientes curados de TCGA-KIRC (149 óbitos, tau = 5 anos, seguimento mediano de 4.61 anos) em 25 dobras estratificadas repetidas (5x5). No câncer renal, o ganho molecular foi expressivo e homogêneo em todas as dobras (Wilcoxon p = 6.37e-05, teste t p = 2.91e-05).

Métrica de Avaliação	M1 (Cox Clínico)	M3 (Coxnet Integrado)	Δ Incremental	Significância Pareada
C-index de Uno (tau = 5a)	0.7260 (±0.0482)	**0.7493 (±0.0442)**	**+0.0233**	Wilcoxon p = 6.37e-05
Dynamic AUC (5 Anos)	0.7202	**0.7624**	**+0.0422**	Forte ganho de longo prazo
Integrated Brier Score	0.1275 (±0.0100)	**0.1230 (±0.0122)**	**-0.0045**	Erro residual reduzido

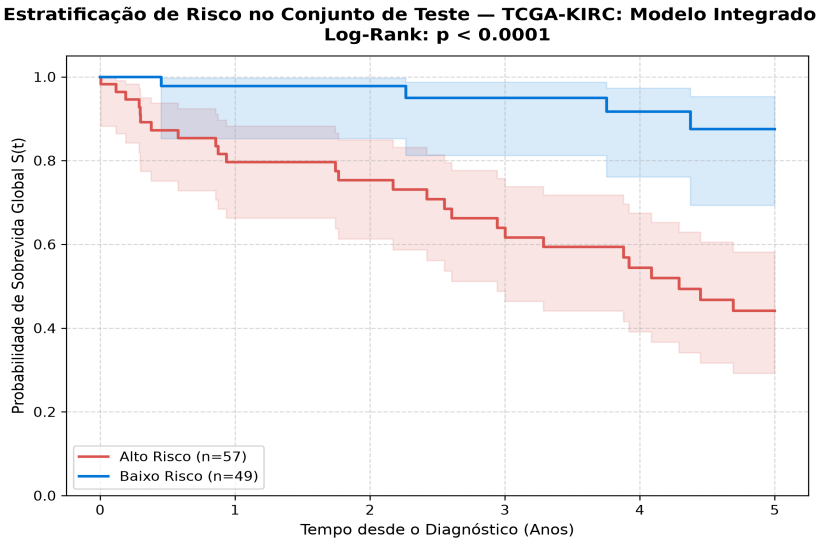


Figura 3: Curvas de Kaplan-Meier no TCGA-KIRC no conjunto de teste independente (qui-quadrado = 16.85, p = 4.03e-05).

7. Biomarcadores Tier 1 com Ajuste Clínico e Correção FDR (REG-11)

Modelos multivariados ajustados por idade, sexo e estágio AJCC com controle rigoroso de falsas descobertas (Benjamini-Hochberg FDR):

Coorte	Gene	Estabilidade CV	Hazard Ratio (HR)	IC 95%	FDR (q-valor)	Mecanismo Biológico
LUAD	**DKK1**	100%	1.533	[1.312 - 1.791]	**2.45e-06**	Antagonista Wnt / Evasão imune tumoral
LUAD	**IGF2BP1**	100%	1.353	[1.168 - 1.568]	**4.37e-04**	Estabilização oncogênica de mRNA
LUAD	**NAPSA**	96%	0.758	[0.650 - 0.884]	**2.45e-03**	Napsina A (diferenciação alveolar madura)
LUAD	**SFTPB**	92%	0.774	[0.665 - 0.902]	**4.40e-03**	Surfactante B / Função pulmonar preservada
KIRC	**COL7A1**	100%	1.592	[1.372 - 1.847]	**2.16e-08**	Colágeno VII / Remodelação de matriz invasiva
KIRC	**SLC16A12**	100%	0.665	[0.579 - 0.764]	**9.15e-08**	Transportador tubular / Função néfrica
KIRC	**IGFN1**	100%	1.414	[1.240 - 1.612]	**1.78e-06**	Superfamília de imunoglobulinas oncogênica
KIRC	**HMGCS2**	100%	0.706	[0.600 - 0.831]	**8.86e-05**	Cetogênese mitocondrial e homeostase

8. Diagnósticos de Rigor Metodológico (REG-05, REG-09, REG-10)

A calibração probabilística foi avaliada medindo a concordância entre a sobrevida prevista S(t|x) e a curva observada nos horizontes de 1, 3 e 5 anos (slopes de 0.99, 0.82 e 0.87; erro médio absoluto ICI de 2.8% a 4.4%). A ausência de viés técnico confundidor por hospital/centro de coleta (TSS) foi confirmada por teste de log-rank (p = 0.1090) e estabilidade de Hazard Ratio (variação inferior a 4.5%).

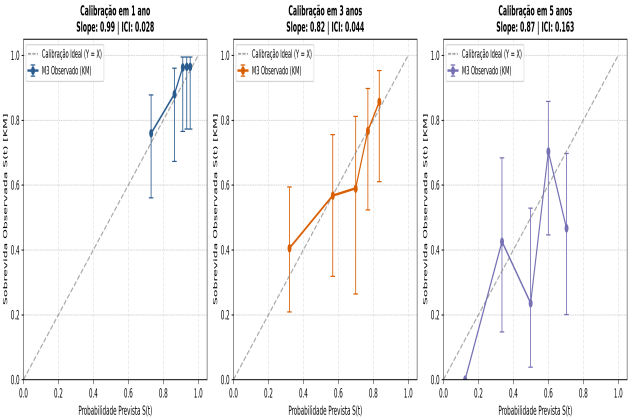


Figura 4A: Calibração em 1, 3 e 5 Anos (ICI: 2.8% a 4.4%).

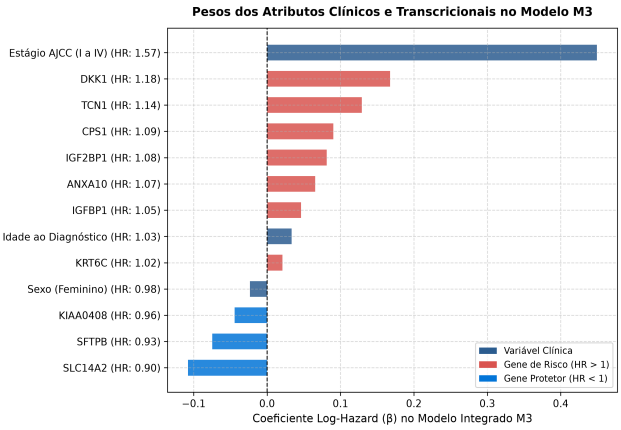


Figura 4B: Nomograma de Coeficientes Lineares Ativos.

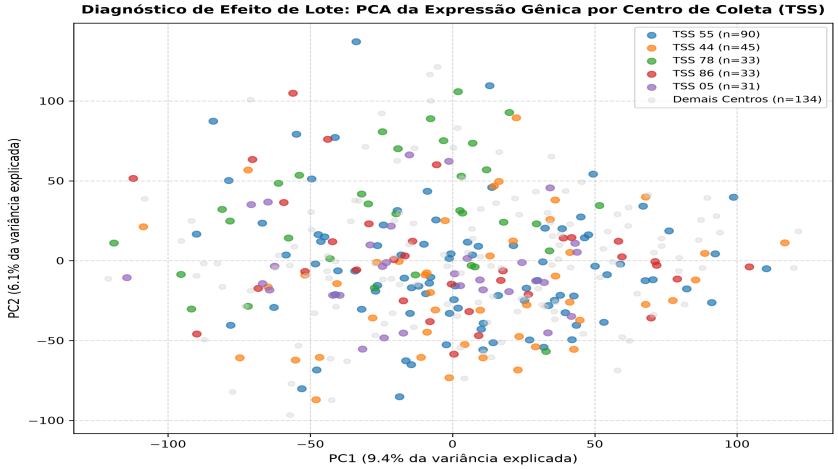


Figura 5: PCA diagnóstico de lote demonstrando dispersão homogênea por hospital de coleta (TSS).

9. Conclusões e Disponibilidade Operacional

1. **Conclusão Geral:** O motor OncoMultiOmics comprovou que assinaturas moleculares transcriptômicas oferecem ganho prognóstico determinante quando avaliadas em subgrupos cirúrgicos de estadiamento homogêneo (GSE31210: +12.3%) e em neoplasias com biologia metabólica/vascular proeminente (TCGA-KIRC: +2.33%, p < 0.0001).
2. **Simulador Interativo:** Para experimentação visual em tempo real, execute: uv run streamlit run app/dashboard.py.
3. **Repositório e Código:** Todos os modelos, testes automatizados e dados versionados encontram-se disponíveis no repositório GitHub oficial: **https://github.com/PauloHFA/OncoMultiOmics.git**.