OncoMultiOmics Survival Engine – Documentação de Análise de Data Science

Predição de prognóstico e sobrevivência oncológica por **Machine Learning de Sobrevivência**, integrando dados clínicos e expressão gênica (RNA-Seq) de bases abertas. Documento técnico completo para conduzir a análise com rigor científico e reprodutibilidade.

1. Resumo e perguntas científicas

Objetivo: estimar, para cada paciente, a **curva de probabilidade de sobrevivência ao longo do tempo** a partir de variáveis clínicas e do perfil de expressão do tumor, medindo se a informação molecular **acrescenta valor preditivo** além do que a clínica já oferece.

ID	Pergunta	Tipo
Q1	A expressão gênica melhora a predição de sobrevivência **além das variáveis clínicas** (idade, estágio, grau)?	Preditiva (principal)
Q2	Qual combinação de redução de dimensionalidade e modelo (Cox penalizado, Random Survival Forest, boosting, DeepSurv) tem melhor discriminação **e calibração**?	Comparativa
Q3	O desempenho se mantém em uma **coorte externa independente**?	Generalização
Q4	Quais genes e vias se associam à sobrevivência de forma **estável** e **independente** das variáveis clínicas?	Exploratória
Q5	O modelo separa pacientes em grupos de risco com curvas de sobrevivência distintas?	Estratificação

Hipóteses falsificáveis:

- **H1:** o modelo clínico + expressão apresenta C-index (Uno) maior do que o modelo apenas clínico, com intervalo de confiança que exclui a diferença nula.
- **H2:** modelos lineares penalizados (Cox elastic net) têm desempenho comparável ou superior a modelos mais complexos nas dimensões de amostra do TCGA.
- **H3:** parte do desempenho observada na validação interna **não se reproduz** na coorte externa (quantificar a perda).

Cada hipótese tem critério de decisão escrito **antes** de abrir o conjunto de teste (REG-14).

2. Revisão crítica da ideia original (ajustes recomendados)

A proposta é boa, mas alguns pontos precisam de ajuste para produzir um resultado **cientificamente válido**. Estes ajustes já estão incorporados no restante do documento.

Ponto da ideia original	Risco	Ajuste adotado
"Multi-ômica" com clínico + RNA-Seq	São duas camadas (clínica e transcriptoma); multi-ômica de verdade inclui mutações, número de cópias e metilação	Tratar como **integração clínico-transcriptômica** no MVP; mutações (MAF), CNV e metilação entram como **extensão**
PCA para "não perder variância biológica"	Variância não é o mesmo que sinal prognóstico; os componentes perdem a interpretação por gene	PCA apenas como **baseline**; priorizar **Cox penalizado (lasso/elastic net)**, escores de **assinaturas gênicas** (GSVA/ssGSEA) e filtro univariado **dentro da validação cruzada**
Desfecho "sobrevivência" sem definição	Em muitos tumores, a sobrevida global inclui mortes não relacionadas ao câncer e o seguimento é curto	Definir o **desfecho conforme o TCGA-CDR** (OS, PFI, DSS ou DFI) e exigir um **número mínimo de eventos** por coorte
"Tratamentos prévios" como variável	Dados de tratamento no TCGA são incompletos e heterogêneos; risco de **viés de confusão por indicação** e de vazamento temporal	Modelo base usa **variáveis de baseline** (diagnóstico); tratamento só em análise de sensibilidade
Avaliar apenas com C-index	O C-index de Harrell depende da censura; mede só ordenação, não calibração	**C-index de Uno com horizonte τ**, AUC dependente do tempo, **Integrated Brier Score** e **calibração**
Divisão treino/teste não especificada	Com poucos pacientes, uma divisão única é instável; seleção de genes no conjunto todo **vaza informação**	**CV repetida estratificada por evento**, validação aninhada para hiperparâmetros e **validação externa**

Ponto da ideia original	Risco	Ajuste adotado
DeepSurv como modelo central	Com algumas centenas de pacientes e milhares de genes, redes neurais costumam **não superar** o Cox penalizado	DeepSurv entra como **comparação opcional**, com regularização forte e múltiplas sementes
"Genes que orientam novas terapias"	Associação prognóstica não é alvo terapêutico; risco de falsos positivos	Reportar **associações ajustadas, com FDR e estabilidade**; linguagem de hipótese, nunca de causalidade
Efeito de lote (centro, placa) ignorado	A origem da amostra (TSS) pode se correlacionar com a sobrevida e gerar sinal espúrio	**Diagnóstico de lote** e análises de sensibilidade (estratificação ou correção)
Várias amostras por paciente	Duplicidade infla o desempenho	**Uma amostra tumoral primária por paciente**

3. Dados

3.1 Fontes

Fonte	Conteúdo	Uso no projeto
GDC / TCGA	Dados clínicos e de expressão harmonizados (hg38). Expressão por fluxo **STAR – Counts** (arquivos de acesso aberto com contagens, TPM e FPKM); BAM e VCF são de **acesso controlado**	Fonte principal de expressão e clínica
TCGA-CDR (Pan-Cancer Clinical Data Resource, Liu et al., *Cell*, 2018)	Desfechos curados (OS, DSS, DFI, PFI) com orientação de qual usar por tipo de tumor	**Definição dos desfechos**

Fonte	Conteúdo	Uso no projeto
cBioPortal (DataHub)	Dados do TCGA prontos em formato tabular (clínico + moleculares), além de outros estudos	Alternativa de download e **coortes externas**
UCSC Xena	Dados do TCGA recomputados em pipeline uniforme	Alternativa de expressão harmonizada
Coortes externas (por exemplo, METABRIC via cBioPortal para mama; coortes de glioma e outras no GEO)	Expressão e sobrevida de pacientes independentes	**Validação externa** (exige harmonização de plataforma)

> Versões de dados, formatos e termos mudam. Na Fase 0, registre **versão do release do GDC, data de download e hash** de cada arquivo, confirme as colunas dos arquivos de expressão e siga as diretrizes de citação do TCGA.

3.2 Como baixar

- **GDC API ou `gdc-client`** com manifesto filtrado (`STAR - Counts`, acesso aberto). Em Python, usar `requests` na API do GDC; **TCGAbiolinks** (R) é a referência para consultas, com função de download e preparo de objetos `SummarizedExperiment`.
- **cBioPortal DataHub** (arquivos tabulares por estudo), indicado para um início mais rápido e para as coortes externas.
- Sempre por **script**, nunca manualmente, e com o manifesto versionado.

3.3 Seleção de coortes

Cada tipo de tumor é analisado **separadamente** (um modelo por coorte); modelo pan-câncer é extensão. Critérios para entrar no estudo:

Critério	Regra (heurística de estudo)
Número de eventos	Eventos suficientes para o desfecho escolhido (como regra prática para Cox, pelo menos 10 eventos por variável candidata em modelos não penalizados; modelos penalizados toleram menos, mas continuam dependentes do número de eventos)

Critério	Regra (heurística de estudo)
Seguimento	Mediana e dispersão adequadas ao horizonte de interesse (por exemplo, 3 e 5 anos)
Dados clínicos	Estágio e idade disponíveis para a maioria dos pacientes
Validação externa	Existência de coorte independente com sobrevida e expressão

Sugestão de coortes (confirmar a contagem real de pacientes e eventos na Fase 1): **LUAD** (adenocarcinoma de pulmão) ou **KIRC** (carcinoma renal de células claras) como piloto, e **BRCA** (mama) com validação externa no METABRIC, ciente de que muitos tumores de mama têm poucos eventos de óbito no seguimento do TCGA. **LGG/GBM** (gliomas) têm marcadores moleculares fortes e servem de caso contrastante.

3.4 Desfecho (endpoint)

Desfecho	Definição resumida	Quando usar
OS (sobrevida global)	Tempo até a morte por qualquer causa	Sempre disponível; inclui mortes não oncológicas
PFI (intervalo livre de progressão)	Tempo até progressão, recorrência ou morte por câncer	Costuma ser recomendado quando o seguimento é curto
DSS (sobrevida específica da doença)	Tempo até morte pela doença	Quando a causa de morte é confiável
DFI (intervalo livre de doença)	Tempo até recorrência após remissão completa	Para tumores com tratamento curativo e recorrência bem registrada

Siga as **recomendações do TCGA-CDR por tipo de câncer** e **escolha o desfecho no plano de análise, antes de modelar**. Trocar de desfecho depois de ver os resultados é *p-hacking*. Defina também um **horizonte máximo τ** (por exemplo, 5 anos) para limitar a cauda de seguimento instável.

4. Pipeline de análise

```
  GDC / cBioPortal / Xena
        |  download versionado
        ▼
  [1] Curadoria clínica + desfecho (OS/PFI/DSS/DFI) + τ
        ▼
  [2] Seleção de amostras: 1 tumor primário por paciente, QC, remoção de
duplicatas
        ▼
  [3] Pré-processamento molecular: genes, normalização, diagnóstico de lote
        ▼
  [4] Divisão: CV repetida estratificada por evento (+ coorte externa
reservada)
        ▼
  [5] Dentro de cada dobra: imputação, padronização, redução de
dimensionalidade
        ▼
  [6] Modelos: KM → Cox clínico → Cox penalizado → RSF → boosting → DeepSurv
        ▼
  [7] Avaliação: C-index (Uno), AUC(t), IBS, calibração, estratificação, ΔC
vs. clínico
        ▼
  [8] Interpretação: coeficientes, estabilidade, SHAP, vias (GSEA)
        ▼
  [9] Validação externa + relatório
```

5. Pré-processamento clínico

5.1 Variáveis candidatas

Variável	Tratamento	Observação
Idade ao diagnóstico	Numérica, em anos	Verificar valores impossíveis
Sexo	Categórica	
Estágio (AJCC)	Agrupar em I a IV (e subestágios quando necessário)	Edições diferentes do AJCC; harmonizar
T, N, M	Categóricas agrupadas	Muitos faltantes em alguns tumores
Grau histológico	Ordinal	Quando existir

Variável	Tratamento	Observação
Subtipo molecular ou histológico	Categórica	Cuidado com subtipos definidos pela própria expressão (circularidade)
Tabagismo (por exemplo, no pulmão)	Categórica ou pacotes-ano	Muitos faltantes
Centro de origem (TSS) e ano do diagnóstico	**Somente diagnóstico de lote**, não como preditor principal	Podem gerar sinal espúrio
Tratamento	**Fora do modelo base**; só em sensibilidade	Dados incompletos e confusão por indicação
Raça e etnia	Descrever a composição; usar com cautela	TCGA tem composição populacional desbalanceada

5.2 Regras de qualidade

- **Tempo e evento:** `tempo` em dias (convertido para meses ou anos) e `evento` binário; descartar tempos ausentes ou não positivos, e registrar quantos pacientes saíram em cada etapa (**funil de exclusão**).
- **Censura:** manter censurados no treino; aplicar o corte administrativo em τ quando definido.
- **Dados faltantes:** relatar a proporção por variável; excluir variáveis com faltantes excessivos; **imputar dentro de cada dobra** (mediana ou moda, ou imputação múltipla) e considerar indicadores de ausência.
- **Categorias raras:** agrupar para evitar colunas quase vazias.
- **Dicionário de dados:** documentar definição, unidade, origem e tratamento de cada variável.

6. Pré-processamento molecular

6.1 Seleção de amostras

- **Uma amostra tumoral primária por paciente.** O código de barras do TCGA identifica paciente (12 primeiros caracteres) e tipo de amostra (por exemplo, `01` = tumor sólido primário).
- Remover amostras normais, metastáticas e recorrentes (a menos que o tipo de tumor exija outra regra, como `06` no melanoma), e filtrar amostras FFPE se houver.

- Em caso de duplicatas do mesmo paciente, escolher por critério fixo e documentado (por exemplo, maior profundidade de leitura).

```
df["paciente"] = df["barcode"].str[:12]
df["tipo_amostra"] = df["barcode"].str[13:15]

tumor = (
    df[df["tipo_amostra"] == "01"]
    .sort_values(["paciente", "barcode"])
    .drop_duplicates("paciente", keep="first")
)
```

6.2 Genes e normalização

Etapa	Regra
Genes	Manter genes codificantes de proteína; padronizar identificadores (Ensembl e símbolo)
Filtro de baixa expressão	Remover genes com expressão baixa na maioria das amostras (limiar documentado, por exemplo, TPM acima de um valor em pelo menos 20% das amostras)
Normalização	**log2(TPM + 1)** como padrão; **VST** (por exemplo, `pydeseq2`) a partir das contagens como análise de sensibilidade
Escala	Padronização por gene **ajustada no treino de cada dobra**
Valores atípicos	Detectar amostras discrepantes por PCA e correlação; decidir e documentar

6.3 Efeito de lote e confusão

- Fazer PCA e colorir por **TSS, placa, centro de sequenciamento e data**; testar a associação desses fatores com a **sobrevida** (um TSS associado à sobrevida é sinal de alerta).
- Se houver lote relevante: análise de sensibilidade com **estratificação por TSS** no Cox ou **correção** (por exemplo, ComBat, usando só covariáveis técnicas e **nunca o desfecho**).
- Estimar **pureza tumoral e infiltração imune** (por exemplo, ESTIMATE ou deconvolução) para usar como covariáveis ou análise de sensibilidade.

6.4 Estratégias de redução de dimensionalidade (comparadas)

Estratégia	Como	Interpretabilidade	Observação
E1 – Cox penalizado com todos os genes filtrados	Elastic net sobre milhares de genes	Alta (coeficientes por gene)	Estratégia principal
E2 – Filtro univariado + modelo	Top-*k* genes por Cox univariado, **dentro da dobra**	Alta	Barata e forte como baseline
E3 – Escores de assinaturas	GSVA/ssGSEA em conjuntos Hallmark, imunes e de proliferação	Alta (nível de via)	Poucas variáveis, mais estáveis
E4 – Assinaturas conhecidas por câncer	Por exemplo, PAM50 em mama	Alta	Comparação com a literatura
E5 – PCA ou PLS	Componentes não supervisionados (PCA) ou supervisionados (PLS)	Baixa	**Baseline**, como na ideia original
E6 – Autoencoder (opcional)	Representação latente	Baixa	Só se houver ganho comprovado

Regra: qualquer etapa que **use o desfecho** (filtro univariado, seleção) ou **aprenda parâmetros** (padronização, PCA) é ajustada **somente no treino de cada dobra**. A filtragem não supervisionada por nível de expressão pode ser feita antes da divisão, desde que documentada.

7. Modelagem

7.1 Escada de modelos (do mais simples ao mais complexo)

Nível	Modelo	Atributos	Biblioteca	Papel
M0	Kaplan-Meier sem covariáveis	–	`lifelines`	Referência nula (C-index de 0,5)
M1	**Cox clínico**	Idade, estágio, grau e demais variáveis de baseline	`lifelines`, `scikit-survival`	**Baseline obrigatório**

Nível	Modelo	Atributos	Biblioteca	Papel
M2	Cox penalizado (elastic net) apenas molecular	Genes filtrados	`scikit-survival` (`CoxnetSurvivalAnalysis`)	Força do sinal molecular isolado
M3	**Cox penalizado clínico + molecular**	Clínica sem penalização (ou escore clínico como offset) + genes	`scikit-survival`	**Modelo integrado principal**
M4	Cox com escores de assinaturas	Clínica + escores GSVA/ssGSEA	`lifelines`, `scikit-survival`	Poucas variáveis, alta interpretabilidade
M5	Random Survival Forest	Clínica + genes selecionados ou escores	`scikit-survival` (`RandomSurvivalForest`)	Não linearidade e interações
M6	Boosting para sobrevivência	Idem	`scikit-survival` (`GradientBoostingSurvivalAnalysis`) ou `xgboost` (`survival:cox`, `survival:aft`)	Não linearidade com regularização
M7 (opcional)	DeepSurv	Clínica + genes ou escores padronizados	`PyTorch`, `pycox`	Comparação com redes neurais
M8 (opcional)	Modelo paramétrico (AFT, Weibull)	Clínica + escores	`lifelines`	Interpretação em escala de tempo

Pergunta decisiva (Q1): M3 supera M1 de forma consistente? Se não superar, esse é um resultado válido e deve ser reportado, e não escondido.

7.2 Hiperparâmetros e treinamento

Modelo	Hiperparâmetros principais
Cox elastic net	`l1_ratio` (0,1 a 1,0) e trajetória de `alpha`; **escolher `alpha` por validação interna** (o padrão da biblioteca usa o último `alpha` da trajetória, o menos regularizado)
Random Survival Forest	`n_estimators`, `min_samples_leaf`, `max_features`, profundidade
Boosting	`learning_rate`, `n_estimators`, `max_depth`, `subsample`, perda (Cox ou AFT)
DeepSurv	1 a 2 camadas ocultas, unidades, *dropout*, *weight decay*, taxa de aprendizado, parada antecipada, **várias sementes**

- **Validação aninhada:** laço externo para estimar o desempenho e laço interno para escolher hiperparâmetros.
- **Objetivo da busca:** C-index de Uno ou IBS, definido no plano de análise.

- **Pressuposto de riscos proporcionais:** verificar nos modelos de Cox com os resíduos de Schoenfeld; se for violado, estratificar, usar modelo AFT ou restringir o horizonte.
- **Riscos competitivos:** em DSS e DFI, mortes por outras causas são eventos concorrentes; declarar a escolha de tratamento.
- **Reprodutibilidade:** sementes fixas e, nos modelos estocásticos, várias sementes com média e dispersão.

8. Validação e métricas

8.1 Estratégia de validação

Estratégia	Como	Uso
CV repetida (5×5) estratificada por evento	Preserva a proporção de eventos em cada dobra	**Avaliação principal**
Validação aninhada	Ajuste de hiperparâmetros no laço interno	Evita otimismo na estimativa
Holdout único (opcional)	Reservado antes de qualquer decisão e **aberto uma vez**	Com poucos pacientes, prefira CV aninhada + coorte externa
Validação externa	Coorte independente com modelo e pontos de corte **congelados**	Resposta a Q3
CV agrupada por centro (TSS)	Deixar centros inteiros fora do treino	Sensibilidade à generalização entre centros

Validação externa: usar apenas os genes em comum, harmonizar a escala dentro de cada coorte (por exemplo, *z-score* ou ranks por gene), tratar diferenças de plataforma (RNA-Seq vs. microarray) e reportar **a perda de desempenho** em relação à interna.

8.2 Métricas

Métrica	O que mede	Observação
C-index de Harrell	Ordenação geral dos riscos	Sensível à censura; usar só como complemento

Métrica	O que mede	Observação
C-index de Uno (com horizonte τ)	Ordenação robusta à censura	**Métrica principal** (`concordance_index_ipcw`); τ deve estar dentro do seguimento do teste
AUC dependente do tempo (1, 3 e 5 anos)	Discriminação em cada horizonte	`cumulative_dynamic_auc`
Brier e IBS	Erro de probabilidade, combinando discriminação e calibração	`integrated_brier_score`; comparar com o modelo nulo (Kaplan-Meier)
Calibração	Probabilidade prevista vs. observada	Curvas por quantis de risco em um horizonte e inclinação de calibração
Estratificação de risco	Razão de risco entre grupos alto e baixo, teste log-rank, curvas de Kaplan-Meier	Ponto de corte **definido no treino**
Valor incremental	ΔC-index em relação a M1, teste de razão de verossimilhança (modelos de Cox aninhados)	Resposta direta a Q1
Intervalos de confiança	*Bootstrap* por paciente (pelo menos 1.000 repetições)	Percentil
Comparação entre modelos	Diferença pareada de C-index com *bootstrap*; teste *t* reamostrado corrigido (Nadeau e Bengio)	Evitar p-valores ingênuos em CV

8.3 Tamanho de amostra e eventos

Reporte, por coorte, **número de pacientes, número de eventos, seguimento mediano (método de Kaplan-Meier reverso) e eventos por variável candidata**. Pouca quantidade de eventos limita o poder e favorece sobreajuste, especialmente em modelos flexíveis.

8.4 Relato

Seguir as diretrizes de relato de modelos prognósticos: **TRIPOD+AI** (modelos de predição) e **REMARK** (estudos de marcadores prognósticos em tumores).

9. Interpretabilidade e biologia

9.1 Métodos

Método	Aplicação	Observação
Coeficientes do Cox penalizado	Direção e magnitude (razão de risco por desvio-padrão)	Instáveis se genes forem muito correlacionados
Estabilidade da seleção	Frequência com que cada gene é selecionado em *bootstraps* ou dobras	Critério central de confiança
Cox univariado e multivariado por gene	Associação **ajustada** às variáveis clínicas, com **correção FDR** (Benjamini-Hochberg)	Evita falsos positivos
Importância por permutação	Random Survival Forest e boosting	Medir queda no C-index
SHAP	Contribuição de cada atributo ao risco (modelos de árvores)	Interpretar como associação ao modelo, não como causa
Enriquecimento de vias (GSEA ou ORA)	Genes ranqueados pela estatística de Cox, em conjuntos Hallmark, Reactome e KEGG (`gseapy`)	Transforma genes em biologia legível
Comparação com assinaturas e literatura	Sobreposição com assinaturas prognósticas publicadas	Valida plausibilidade

9.2 Critérios de credibilidade para um gene candidato

- **Estável** em reamostragens (por exemplo, selecionado na grande maioria das repetições, com limiar definido no plano).
- **Significativo após FDR** e **ajustado** por idade, estágio e demais covariáveis.
- **Mesma direção de efeito** na coorte externa.
- **Não explicado** por pureza tumoral, infiltração imune, proliferação ou efeito de lote.
- **Plausível biologicamente**, com apoio na literatura.

9.3 Cuidados

- Associação prognóstica **não é alvo terapêutico**: evitar linguagem de causalidade ou de indicação de tratamento.
- Genes correlacionados dividem a importância de forma arbitrária; reportar **módulos ou vias**, além de genes isolados.
- Reportar também os genes que **não** se sustentaram na validação externa.

10. Estrutura do repositório

```
onco-survival/
├── README.md
├── pyproject.toml              # dependências travadas
├── Makefile                    # make data | features | train | evaluate |
report | test
├── docs/
|   ├── plano_de_analise.md     # hipóteses, desfecho, τ, métricas (antes de
modelar)
|   ├── dicionario_de_dados.md
|   └── decisoes/               # registros de decisão (ADRs)
├── data/
|   ├── raw/                    # nunca editado; versionado por hash
|   ├── interim/
|   ├── processed/
|   └── external/               # coortes de validação externa
├── src/oncosurv/
|   ├── ingestao/               # GDC, cBioPortal, TCGA-CDR
|   ├── clinico/                # curadoria e desfechos
|   ├── expressao/              # filtros, normalização, lote
|   ├── features/               # assinaturas, seleção, redução
|   ├── modelos/                # Cox, RSF, boosting, DeepSurv
|   ├── validacao/              # CV, métricas, calibração, bootstrap
|   ├── explicabilidade/        # estabilidade, SHAP, enriquecimento
|   └── visualizacao/
├── notebooks/                  # exploração e narrativa
├── tests/                      # unitários, anti-vazamento, contratos de
dados
└── reports/                    # relatório Quarto e figuras
```

11. Esqueletos de código de referência

> Confirme as assinaturas das funções na versão instalada das bibliotecas.

11.1 Desfecho, validação cruzada e C-index de Uno

```
import numpy as np
from sksurv.util import Surv
from sksurv.linear_model import CoxnetSurvivalAnalysis
from sksurv.metrics import concordance_index_ipcw, cumulative_dynamic_auc
from sklearn.model_selection import RepeatedStratifiedKFold, GridSearchCV,
KFold
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

y = Surv.from_arrays(event=dados["evento"].astype(bool),
time=dados["tempo_dias"])
TAU = 5 * 365.25
HORIZONTES = np.array([1, 3, 5]) * 365.25

def ajustar_coxnet(X_tr, y_tr, alphas):
    base = make_pipeline(
        StandardScaler(),
        CoxnetSurvivalAnalysis(l1_ratio=0.5, fit_baseline_model=True,
max_iter=100_000),
    )
    grade = {"coxnetsurvivalanalysis__alphas": [[a] for a in alphas]}
    busca = GridSearchCV(base, grade, cv=KFold(5, shuffle=True,
random_state=0), n_jobs=-1)
    return busca.fit(X_tr, y_tr)      # pontuação padrão: C-index

cv = RepeatedStratifiedKFold(n_splits=5, n_repeats=5, random_state=42)
resultados = []

for treino, teste in cv.split(X, y["event"]):
    # padronização, seleção e escolha de alpha usam SOMENTE o treino desta
dobra
    modelo = ajustar_coxnet(X.iloc[treino], y[treino], alphas_candidatos)
    risco = modelo.predict(X.iloc[teste])
    c_uno = concordance_index_ipcw(y[treino], y[teste], risco, tau=TAU)[0]
    auc_t, auc_medio = cumulative_dynamic_auc(y[treino], y[teste], risco,
HORIZONTES)
    resultados.append({"c_uno": c_uno, "auc_medio": auc_medio})
```

11.2 Estratificação de risco com ponto de corte do treino

```
from lifelines import KaplanMeierFitter
from lifelines.statistics import logrank_test

corte = np.median(risco_treino)            # definido no treino, nunca no
teste
alto = risco_teste > corte

resultado = logrank_test(
    tempo_teste[alto], tempo_teste[~alto],
    event_observed_A=evento_teste[alto],
event_observed_B=evento_teste[~alto],
)
print(resultado.p_value)

km = KaplanMeierFitter()
km.fit(tempo_teste[alto], evento_teste[alto], label="Alto risco")
```

11.3 Pressuposto de riscos proporcionais

```
from lifelines import CoxPHFitter
from lifelines.statistics import proportional_hazard_test

cph = CoxPHFitter(penalizer=0.1).fit(clinico, duration_col="tempo",
event_col="evento")
proportional_hazard_test(cph, clinico, time_transform="rank").print_summary()
```

12. Stack tecnológica

Área	Ferramentas
Download	API do GDC (`requests`), `gdc-client` , cBioPortal DataHub; **TCGAbiolinks** (R) como referência de consulta
Dados	`pandas` ou `polars` , `pyarrow` (Parquet), `numpy` , `scipy`
Sobrevivência	**`scikit-survival`** , **`lifelines`**
Machine learning	`scikit-learn` , `xgboost` , `optuna`
Deep learning (opcional)	`PyTorch` , `pycox`

Área	Ferramentas
Expressão	`pydeseq2` (VST), `inmoose` (ComBat), `gseapy` (GSEA e GSVA)
Explicabilidade	`shap`, `scikit-learn` (importância por permutação)
Visualização	`matplotlib`, `seaborn`, `plotly`
Qualidade de dados	`pandera`
Reprodutibilidade	`uv` ou `poetry`, DVC ou Make, `pre-commit`, `ruff`, `pytest`
Experimentos	MLflow
Relatório	Quarto ou Jupyter Book

13. Regras de rigor científico (obrigatórias)

ID	Regra	Verificação
REG-01	**Uma amostra tumoral primária por paciente**; sem duplicatas	Teste automatizado
REG-02	**Desfecho e horizonte τ definidos antes de modelar**, conforme o TCGA-CDR	Plano de análise
REG-03	Padronização, imputação, seleção de genes e redução de dimensionalidade ajustadas **somente no treino de cada dobra**	Teste anti-vazamento
REG-04	**Baseline clínico (M1) obrigatório**; reportar o valor incremental do molecular	Relatório
REG-05	Reportar C-index de Uno, AUC dependente do tempo, IBS e **calibração**, e não só o C-index	Relatório
REG-06	CV repetida estratificada por evento e **validação aninhada** para hiperparâmetros	Revisão de código
REG-07	Intervalos de confiança por *bootstrap* **por paciente**	Relatório
REG-08	**Validação externa** antes de qualquer alegação de generalização	Relatório

ID	Regra	Verificação
REG-09	**Diagnóstico de lote e de TSS** com análise de sensibilidade	Relatório
REG-10	Pressuposto de riscos proporcionais verificado nos modelos de Cox	Relatório
REG-11	Testes por gene com **FDR** e **ajuste clínico**	Relatório
REG-12	Pontos de corte de risco **fixados no treino**; proibido otimizar corte pelo menor p-valor	Revisão
REG-13	Relatar pacientes, eventos, seguimento mediano, eventos por variável e **funil de exclusão**	Relatório
REG-14	**Plano de análise registrado** antes de abrir o teste final ou a coorte externa, que são **abertos uma única vez**	Commit com data
REG-15	Reprodutibilidade: ambiente travado, versão do release do GDC, hashes dos dados, sementes	CI
REG-16	Linguagem de **associação**, nunca de causalidade; uso exclusivamente de pesquisa	Revisão
REG-17	Resultados nulos ou ganhos pequenos são reportados como tal	Relatório

14. Plano em fases

Fase	Entrega	Critério de aceite	Duração sugerida
0 – Fundação	Repositório, ambiente, CI, plano de análise, escolha de coortes e desfecho	Plano versionado antes de qualquer modelo	1 semana
1 – Dados e curadoria	Download versionado, desfechos do TCGA-CDR, 1 amostra por paciente, funil de exclusão	Tabela final de pacientes, eventos e seguimento documentada	2 semanas

Fase	Entrega	Critério de aceite	Duração sugerida
2 – QC e exploração	Dados faltantes, PCA por lote e TSS, Kaplan-Meier descritivo, pureza tumoral	Relatório de qualidade com limitações dos dados	1 a 2 semanas
3 – Baselines clínicos	M0 e M1, teste de riscos proporcionais, validação funcionando	Teste anti-vazamento verde e métricas reproduzíveis	1 semana
4 – Modelos moleculares e integrados	M2 a M6, estratégias E1 a E5, validação aninhada	Comparação com IC e conclusão honesta sobre Q1 e Q2	2 a 3 semanas
5 – Validação e calibração	Calibração, estratificação, validação externa, sensibilidade a lote	Perda de desempenho externa quantificada (Q3)	2 semanas
6 – Interpretação e biologia	Estabilidade, SHAP, GSEA, comparação com assinaturas	Genes candidatos classificados pelos critérios da seção 9.2	2 semanas
7 – Deep learning (opcional)	DeepSurv com múltiplas sementes	Comparação justa com M3	1 a 2 semanas
8 – Comunicação	Relatório final, README, demonstração e, opcionalmente, painel de pesquisa	Qualquer pessoa reproduz os resultados com um comando	1 semana

15. Riscos e armadilhas

Risco	Prob.	Impacto	Mitigação
Vazamento por seleção de genes, PCA ou padronização no conjunto inteiro	Alta	Alto	REG-03 e teste anti-vazamento
Otimismo por avaliação em uma única divisão ou sem validação externa	Alta	Alto	CV repetida, aninhada e coorte externa

Risco	Prob.	Impacto	Mitigação
Poucos eventos para a dimensionalidade	Alta	Alto	Penalização, assinaturas, coortes com eventos suficientes
Efeito de lote (TSS, placa) associado à sobrevida	Média	Alto	Diagnóstico, estratificação e sensibilidade
Escolha de desfecho após ver resultados	Média	Alto	Plano pré-registrado (REG-02 e REG-14)
Corte de risco otimizado no teste	Média	Alto	Corte fixado no treino (REG-12)
Viés de tempo imortal e confusão por indicação nos dados de tratamento	Média	Médio	Variáveis de baseline; tratamento só em sensibilidade
Seguimento curto e mortes não oncológicas em OS	Alta	Médio	Escolha de desfecho pelo TCGA-CDR e horizonte τ
Violação de riscos proporcionais	Média	Médio	Teste de Schoenfeld, estratificação ou AFT
Redes neurais sobreajustadas	Alta	Médio	Regularização forte, várias sementes, comparação com Cox
Composição populacional do TCGA pouco diversa	Alta	Médio	Declarar a limitação; não extrapolar
Diferenças de plataforma na validação externa	Alta	Médio	Harmonização e relato da perda de desempenho
Múltiplas amostras por paciente	Média	Alto	REG-01
Estágio definido por edições diferentes do AJCC	Média	Médio	Harmonização documentada

16. Ética e uso responsável

- Os dados são **públicos e desidentificados** (acesso aberto); não tente reidentificar pacientes e respeite as **políticas de uso e de citação** do TCGA e do GDC.
- O projeto é de **pesquisa e demonstração técnica**. Não é ferramenta clínica nem deve orientar decisões sobre tratamento.
- Um modelo que apoie decisão clínica pode ser enquadrado como **software como dispositivo médico** (por exemplo, pela ANVISA no Brasil), exigindo validação prospectiva e regularização, o que está fora do escopo.

- **Equidade:** relate a composição por sexo e ancestralidade e discuta o risco de desempenho pior em grupos sub-representados.
- Comunique **incerteza** (intervalos e calibração) em vez de apresentar previsões como certezas.

17. Entregáveis e critérios de sucesso

- Repositório reproduzível com um comando (`make` ou equivalente) e dados versionados.
- **Plano de análise** e **dicionário de dados**.
- Relatório (Quarto) respondendo Q1 a Q5, com métricas e intervalos, calibração, estratificação, validação externa e limitações.
- **Modelos salvos** com *model card* e lista de dependências.
- Notebook de interpretação com genes e vias candidatas classificados por credibilidade.
- Demonstração (opcional): painel de pesquisa que mostra a curva de sobrevivência prevista e as contribuições, **com aviso de uso exclusivo em pesquisa**.

Critérios de sucesso (metas de estudo, não garantias): pipeline sem vazamento comprovado por teste; M3 comparado de forma honesta com M1 (com ΔC-index e IC); calibração e IBS reportados; validação externa realizada e perda quantificada; genes candidatos apresentados com estabilidade e ajuste clínico.

18. Referências

- The Cancer Genome Atlas Research Network e diretrizes de citação do TCGA e do GDC.
- Liu, J. et al. (2018) — "An Integrated TCGA Pan-Cancer Clinical Data Resource to Drive High-Quality Survival Outcome Analytics", *Cell*.
- Cox, D. R. (1972) — "Regression Models and Life-Tables", *JRSS B*.
- Simon, N. et al. (2011) — "Regularization Paths for Cox's Proportional Hazards Model via Coordinate Descent", *Journal of Statistical Software*.
- Ishwaran, H. et al. (2008) — "Random Survival Forests", *The Annals of Applied Statistics*.
- Katzman, J. et al. (2018) — "DeepSurv: personalized treatment recommender system using a Cox proportional hazards deep neural network", *BMC Medical Research Methodology*.
- Pölsterl, S. (2020) — "scikit-survival: A Library for Time-to-Event Analysis Built on Top of scikit-learn", *JMLR*.

- Davidson-Pilon, C. (2019) — "lifelines: survival analysis in Python", *Journal of Open Source Software*.
- Uno, H. et al. (2011) — "On the C-statistics for evaluating overall adequacy of risk prediction procedures with censored survival data", *Statistics in Medicine*.
- Graf, E. et al. (1999) — "Assessment and comparison of prognostic classification schemes for survival data", *Statistics in Medicine*.
- Heagerty, P. et al. (2000) — "Time-dependent ROC curves for censored survival data", *Biometrics*.
- Hänzelmann, S. et al. (2013) — "GSVA: gene set variation analysis", *BMC Bioinformatics*; Subramanian, A. et al. (2005) — GSEA, *PNAS*.
- Johnson, W. E. et al. (2007) — "Adjusting batch effects in microarray expression data using empirical Bayes methods" (ComBat), *Biostatistics*.
- Colaprico, A. et al. (2016) — TCGAbiolinks, *Nucleic Acids Research*; Cerami, E. et al. (2012) — cBioPortal, *Cancer Discovery*; Goldman, M. et al. (2020) — UCSC Xena, *Nature Biotechnology*.
- Curtis, C. et al. (2012) — METABRIC, *Nature*.
- Collins, G. et al. (2024) — TRIPOD+AI, *BMJ*; McShane, L. et al. (2005) — REMARK, *Journal of the National Cancer Institute*.
- Lundberg, S. e Lee, S.-I. (2017) — SHAP, NeurIPS.
- Nadeau, C. e Bengio, Y. (2003) — "Inference for the Generalization Error", *Machine Learning*.

19. Próximo passo

Escolher a **coorte piloto** (sugestão: LUAD ou KIRC), o **desfecho** (consultar o TCGA-CDR) e o **horizonte τ**, e iniciar a **Fase 0**. A primeira prova de valor é o **baseline clínico (M1)** funcionando com validação cruzada sem vazamento, pois ele define o patamar que o modelo molecular precisa superar.